



Spark 官方文档中文翻译

在 Spark 上访问 OpenStack Swift (v1.2.0)

翻译者 杨木

Spark 官方文档翻译团成员

前 言

伴随着大数据相关技术和产业的逐步成熟，继 Hadoop 之后，Spark 技术以集大成的无可比拟的优势，发展迅速，将成为替代 Hadoop 的下一代云计算、大数据核心技术。

Spark 是当今大数据领域最活跃最热门的高效大数据通用计算平台，基于 RDD，Spark 成功的构建起了一体化、多元化的大数据处理体系，在“One Stack to rule them all”思想的引领下，Spark 成功的使用 Spark SQL、Spark Streaming、MLLib、GraphX 近乎完美的解决了大数据中 Batch Processing、Streaming Processing、Ad-hoc Query 等三大核心问题，更为美妙的是在 Spark 中 Spark SQL、Spark Streaming、MLLib、GraphX 四大子框架和库之间可以无缝的共享数据和操作，这是当今任何大数据平台都无可匹敌的优势。

在实际的生产环境中，世界上已经出现很多一千个以上节点的 Spark 集群，以 eBay 为例，eBay 的 Spark 集群节点已经超过 2000 个，Yahoo！等公司也在大规模的使用 Spark，国内的淘宝、腾讯、百度、网易、京东、华为、大众点评、优酷土豆等也在生产环境下深度使用 Spark。2014 Spark Summit 上的信息，Spark 已经获得世界 20 家顶级公司的支持，这些公司中包括 Intel、IBM 等，同时更重要的是包括了最大的四个 Hadoop 发行商，都提供了对 Spark 非常强有力的支持。

与 Spark 火爆程度形成鲜明对比的是 Spark 人才的严重稀缺，这一情况在中国尤其严重，这种人才的稀缺，一方面是由于 Spark 技术在 2013、2014 年才在国内的一些大型企业里面被逐步应用，另一方面是由于匮乏 Spark 相关的中文资料和系统化的培训。为此，Spark 亚太研究院和 51CTO 联合推出了“Spark 亚太研究院决胜大数据时代 100 期公益大讲堂”，来推动 Spark 技术在国内的普及及落地。

具体视频信息请参考 http://edu.51cto.com/course/course_id-1659.html

与此同时，为了向 Spark 学习者提供更为丰富的学习资料，Spark 亚太研究院去年 8 月发起并号召，结合网络社区的力量构建了 Spark 中文文档专家翻译团队，翻译了 Spark 中文文档 V1.1.0 版本。2014 年 12 月，Spark 官方团队发布了 Spark 1.2.0 版本，为了让学习者了解到最新的内容，Spark 中文文档专家翻译团队又对 Spark 1.2.0 版本进行了部分更新，在此，我谨代表 Spark 亚太研究院及广大 Spark 学习爱好者向专家翻译团队所有成员热情而专业的工作致以深刻的敬意！

当然，作为相对系统的 Spark 中文文档，不足之处在所难免，大家有任何建议或者意见都可以发邮件到 marketing@sparkinchina.com；同时如果您想加入 Spark 中文文档翻译团队，也请发邮件到 marketing@sparkinchina.com 进行申请；Spark 中文

文档的翻译是一个持续更新的、不断版本迭代的过程，我们会尽全力给大家提供更高质量的 Spark 中文文档翻译。

最后，也是最重要的，请允许我荣幸的介绍一下我们的 Spark 中文文档 1.2.0 版本翻译的专家团队成员，他们分别是（排名不分先后）：

- ▶ 傅智勇,《快速开始(v1.2.0)》
- ▶ 王宇舟,《Spark 机器学习库 (v1.2.0)》
- ▶ 武扬,《在 Yarn 上运行 Spark (v1.2.0)》《Spark 调优(v1.2.0)》
- ▶ 徐骄,《Spark 配置(v1.2.0)》《Spark 作业调度(v1.2.0)》
- ▶ 蔡立宇,《Bagel 编程指南(v1.2.0)》
- ▶ harli,《Spark 编程指南 (v1.2.0)》
- ▶ 韩保礼,《Spark SQL 编程指南(v1.2.0)》
- ▶ 李丹丹,《文档首页(v1.2.0)》
- ▶ 李军,《Spark 实时流处理编程指南(v1.2.0)》
- ▶ 俞杭军,《使用 Maven 编译 Spark(v1.2.0)》
- ▶ 王之,《给 Spark 提交代码(v1.2.0)》
- ▶ Ernest,《集群模式概览(v1.2.0)》《监控与相关工具(v1.2.0)》《提交应用程序(v1.2.0)》
- ▶ 杨木,《在 Spark 中访问 OpenStack Swift》《Spark 概览》

Life is short, You need Spark!

Spark 亚太研究院院长 王家林
2015 年 2 月

Spark 亚太研究院决胜大数据时代 100 期公益大讲堂

简介

作为下一代云计算的核心技术,Spark 性能超 Hadoop 百倍,算法实现仅有其 1/10 或 1/100,是可以革命 Hadoop 的目前唯一替代者,能够做 Hadoop 做的一切事情,同时速度比 Hadoop 快了 100 倍以上。目前 Spark 已经构建了自己的整个大数据处理生态系统,国外一些大型互联网公司已经部署了 Spark。甚至连 Hadoop 的早期主要贡献者 Yahoo 现在也在多个项目中部署使用 Spark。国内的淘宝、优酷土豆、网易、Baidu、腾讯、皮皮网等已经使用 Spark 技术用于自己的商业生产系统中,国内外的应用开始越来越广泛。Spark 正在逐渐走向成熟,并在这个领域扮演更加重要的角色,刚刚结束的 2014 Spark Summit 上的信息,Spark 已经获得世界 20 家顶级公司的支持,这些公司中包括 Intel、IBM 等,同时更重要的是包括了最大的四个 Hadoop 发行商都提供了对非常强有力的支持 Spark 的支持。

鉴于 Spark 的巨大价值和潜力,同时由于国内极度缺乏 Spark 人才,Spark 亚太研究院在完成了对 Spark 源码的彻底研究的同时,不断在实际环境中使用 Spark 的各种特性的基础之上,推出了 Spark 亚太研究院决胜大数据时代 100 期公益大讲堂,希望能够帮助大家了解 Spark 的技术。同时,对 Spark 人才培养有进一步需求的企业和个人,我们将以公开课和企业内训的方式,来帮助大家进行 Spark 技能的提升。同样,我们也为企业提供一体化的顾问式服务及 Spark 一站式项目解决方案和实施方案。

Spark 亚太研究院决胜大数据时代 100 期公益大讲堂是国内第一个 Spark 课程免费线上讲座,每周一期,从 7 月份起,每周四晚 20:00-21:30,与大家不见不散!老师将就 Spark 内核剖析、源码解读、性能优化及商业实战案例等精彩内容与大家分享,干货不容错过!

时间:从 7 月份起,每周一期,每周四晚 20:00-21:30

形式:腾讯课堂在线直播

学习条件:对云计算大数据感兴趣的技术人员

课程学习地址:http://edu.51cto.com/course/course_id-1659.html

在 Spark 上访问 OpenStack Swift (翻译者：杨木)

Accessing OpenStack Swift from Spark , 原文档链接：

<http://spark.apache.org/docs/latest/storage-openstack-swift.html>

目录

1. 在 Spark 上访问 OpenStack Swift..... 错误！未定义书签。
2. 配置 Swift 获得更好的数据局部性 错误！未定义书签。6
3. 依赖 错误！未定义书签。6
4. 参数配置 错误！未定义书签。6

1. 在 Spark 上访问 OpenStack Swift

Spark 对 Hadoop 输入格式的支持允许它使用相同的 URL 格式处理 OpenStack Swift 中的数据。你可以以 `swift://container.PROVIDER/path` 的 URL 格式指定 Swift 中的输入路径。你还需要配置 `core-site.xml` 或者通过 `SparkContext.hadoopConfiguration` 设置你的 Swift 安全证书。当前的 Swift driver 需要使用 KeyStone 认证方法。

2. 配置 Swift 获得更好的数据局部性

即使不是必要的，建议你配置 Swift 的代理服务器并配置 `list_endpoints` 参数，这样你能得到更好的数据局部性。在[这里](#)能获得更多的信息。

3. 依赖

Spark 应用应该包含 `hadoop-openstack` 依赖。举例来说，在 `pom.xml` 文件中加入如下配置可以使 Maven 提供相应支持。

```
<dependencyManagement>

...

<dependency>

  <groupId>org.apache.hadoop</groupId>

  <artifactId>hadoop-openstack</artifactId>

  <version>2.3.0</version>

</dependency>

...

</dependencyManagement>
```

4. 参数配置

在 Spark 的 `conf` 目录中建立 `core-site.xml` 文件。这里有两类重要的参数需要配置：Swift driver 的声明以及 Keystone 需要配置的参数。

Hadoop 使用 Swift 文件系统的相关配置

Property Name	Value
fs.swift.impl	org.apache.hadoop.fs.swift.snative.SwiftNativeFileSystem

另外还有一些被 Keystone(v2.0)需要的参数也应该提供给 Swift driver。在访问 Swift 的时候这些参数将在 Keystone 被用来执行认证。下表列举了 Keystone 的必要参数，其中 PROVIDER 能被任何名字替代。

Property Name	Meaning	Required
fs.swift.service.PROVIDER.auth.url	Keystone Authentication URL	Mandatory
fs.swift.service.PROVIDER.auth.endpoint.prefix	Keystone endpoints prefix	Optional
fs.swift.service.PROVIDER.tenant	Tenant	Mandatory
fs.swift.service.PROVIDER.username	Username	Mandatory
fs.swift.service.PROVIDER.password	Password	Mandatory
fs.swift.service.PROVIDER.http.port	HTTP port	Mandatory
fs.swift.service.PROVIDER.region	Keystone region	Mandatory
fs.swift.service.PROVIDER.public	Indicates if all URLs are public	Mandatory

例如，我们假设 PROVIDER=SparkTest 并且 Keystone 为 tenant 测试定义了一个 tester 用户，用户密码为 testing。那么在 core-site.xml 文件中应该包含：

```
<configuration>
  <property>
    <name>fs.swift.impl</name>
    <value>org.apache.hadoop.fs.swift.snative.SwiftNativeFileSystem</value>
  </property>
  <property>
    <name>fs.swift.service.SparkTest.auth.url</name>
    <value>http://127.0.0.1:5000/v2.0/tokens</value>
  </property>
</configuration>
```

```
</property>
<property>
  <name>fs.swift.service.SparkTest.auth.endpoint.prefix</name>

  <value>endpoints</value>
</property>
<property>
  <name>fs.swift.service.SparkTest.http.port</name>

  <value>8080</value>
</property>
<property>
  <name>fs.swift.service.SparkTest.region</name>

  <value>RegionOne</value>
</property>
<property>
  <name>fs.swift.service.SparkTest.public</name>

  <value>true</value>
</property>
<property>
  <name>fs.swift.service.SparkTest.tenant</name>

  <value>test</value>
</property>
<property>
  <name>fs.swift.service.SparkTest.username</name>

  <value>tester</value>
</property>
<property>
  <name>fs.swift.service.SparkTest.password</name>

  <value>testing</value>
</property>
</configuration>
```


注意参数 `fs.swift.service.PROVIDER.tenant` ,`fs.swift.service.PROVIDER.username` ,`fs.swift.service.PROVIDER.password` 包含敏感信息,将它们配置在 `core-site.xml` 中并不是一个好方法。我们建议当使用 `spark-shell` 运行 Spark 进行测试的时候将这些参数配置在 `core-site.xml` 中。当提交作业的时候它们应该通过 `sparkContext.hadoopConfiguration` 提供。

■ Spark 亚太研究院

Spark 亚太研究院是中国最专业的一站式大数据 Spark 解决方案供应商和高品质大数据企业级完整培训与服务供应商,以帮助企业规划、架构、部署、开发、培训和使用 Spark 为核心,同时提供 Spark 源码研究和应用技术训练。针对具体 Spark 项目,提供完整而彻底的解决方案。包括 Spark 一站式项目解决方案、Spark 一站式项目实施方案及 Spark 一体化顾问服务。

官网: www.sparkinchina.com

■ 视频课程:

《大数据 Spark 实战高手之路》 国内第一个 Spark 视频系列课程

从零起步,分阶段无任何障碍逐步掌握大数据统一计算平台 Spark,从 Spark 框架编写和开发语言 Scala 开始,到 Spark 企业级开发,再到 Spark 框架源码解析、Spark 与 Hadoop 的融合、商业案例和企业面试,一次性彻底掌握 Spark,成为云计算大数据时代的幸运儿和弄潮儿,笑傲大数据职场和人生!

- ▶ 第一阶段:熟练的掌握 Scala 语言
课程学习地址: <http://edu.51cto.com/pack/view/id-124.html>
- ▶ 第二阶段:精通 Spark 平台本身提供给开发者 API
课程学习地址: <http://edu.51cto.com/pack/view/id-146.html>
- ▶ 第三阶段:精通 Spark 内核
课程学习地址: <http://edu.51cto.com/pack/view/id-148.html>
- ▶ 第四阶段:掌握基于 Spark 上的核心框架的使用
课程学习地址: <http://edu.51cto.com/pack/view/id-149.html>
- ▶ 第五阶段:商业级别大数据中心黄金组合: Hadoop+ Spark
课程学习地址: <http://edu.51cto.com/pack/view/id-150.html>
- ▶ 第六阶段: Spark 源码完整解析和系统定制
课程学习地址: <http://edu.51cto.com/pack/view/id-151.html>

■ 图书：
《大数据 spark 企业级实战》

京东购买官网：<http://item.jd.com/11622851.html>

当当购买官网：<http://product.dangdang.com/23631792.html>

亚马逊购买官网：<http://www.amazon.cn/dp/B00RMD8K12/>



目前市面上最全最实战的
SPARK图书!

Life is short,
you need Spark!

大数据Spark
企业级实战

Spark亚太研究院 王家林 编著
ISBN 978-7-121-24744-6

当今大数据时代
最具学习价值的技术宝典
重新点燃诸多骨灰级IT大咖激情!

咨询电话：4006-998-758

QQ 交流群：1 群：317540673 (已满)

2 群：297931500 (已满)

3 群：317176983

4 群：324099250



微信公众号：spark-china